

НЕЙРОСЕТЕВОЙ ПОДХОД К РЕШЕНИЮ ОБРАТНЫХ ЗАДАЧ ТЕОРИИ АНОМАЛЬНОЙ ДИФФУЗИИ*)

А. Н. Бондаренко, Т. В. Бугуева, В. А. Дедок

Представлены результаты компьютерного моделирования работы трехслойного персептрона, обученного для решения обратных задач теории аномальной диффузии. Рассмотрены несколько типов обратных задач, включающих задачу определения показателя Хёрста самоподобной среды.

Ключевые слова: аномальная диффузия, обратные задачи, искусственные нейронные сети.

DOI 10.17377/SIBJIM.2016.19.301

1. Задачи аномальной диффузии. Математические модели, использующие методы дробного анализа, широко применяются в различных областях науки, как теоретической, так и прикладной. В работе [1] было выяснено, что замена производной по времени в уравнении диффузии на оператор дробного дифференцирования может описывать эффекты памяти. Особенностью таких процессов является отклонение среднеквадратичного отклонения от классической гауссовской (соответствующей закону $\langle x^2(t) \rangle \sim K_1 t$) диффузии: $\langle x^2(t) \rangle = \frac{2K_\alpha}{\Gamma(1+\alpha)} t^\alpha$. Интерес к так называемым процессам аномальной диффузии обусловлен возможностями исследования диффузионных процессов в средах, демонстрирующих эффект памяти, например в так называемых самоподобных средах. Такие материалы становятся все более популярными из-за их необычных свойств. Наиболее известный пример такого материала — осажденные в невесомости пары алюминия. Обладая необычайно низкой плотностью и достаточной прочностью, он представляет собой идеальный материал будущего, например для строительства космических модулей. В этом случае актуальной становится задача неразрушающего контроля таких материалов.

2. Математические методы теории аномальной диффузии. В теории аномальной диффузии рассматриваются два схожих, но в общем случае не совпадающих понятия дробной производной (дробные производные Капуто и Римана — Лиувилля), которые в работе [2] определяются следующим образом.

ОПРЕДЕЛЕНИЕ 1. Дробной производной Капуто порядка α функции $f(t)$ называется выражение

$${}_t\mathcal{D}_*^\alpha f(t) = \frac{1}{\Gamma(1-\alpha)} \int_0^t \frac{f'(\tau)}{(t-\tau)^\alpha} d\tau, \quad 0 < \alpha < 1. \quad (1)$$

*) Работа выполнена при частичной финансовой поддержке Российского фонда фундаментальных исследований (проект 14-01-00208) и мэрии города Новосибирска (муниципальный грант для молодых ученых).

ОПРЕДЕЛЕНИЕ 2. Дробной производной Римана — Лиувилля порядка α функции $f(t)$ называется выражение

$${}_t D^\alpha f(t) = \frac{1}{\Gamma(1-\alpha)} \frac{d}{dt} \int_0^t \frac{f(\tau)}{(t-\tau)^\alpha} d\tau, \quad 0 < \alpha < 1. \quad (2)$$

С физической точки зрения уравнение аномальной диффузии (УАД) ${}_t D^\alpha u(x, t) = \lambda \Delta u(x, t)$ выводится из дробного закона Фика, который описывает процессы переноса с длинной памятью. Фундаментальное решение соответствующей задачи Коши интерпретируется как плотность вероятности самоподобного немарковского вероятностного процесса [3], связанного с явлением субдиффузии (дисперсия растет во времени сублинейно).

Одним из подходов, используемых в теории аномальной диффузии, является подход, основанный на концепции метода случайного блуждания, который был введен и проанализирован в работе [4] как непрерывный по времени метод случайного блуждания и развит в [5]. В работах [6, 7] показано, как схема конечных разностей служит дискретной моделью метода случайного блуждания.

Область обратных задач для УАД находится в стадии бурного развития. Первая существенная практическая формулировка обратной задачи для УАД была представлена в [8, 9], где было рассмотрено дробное обобщение классической задачи Зоммерфельда. Задача состояла в восстановлении параметров α и λ задачи с периодическим источником без граничных условий:

$${}_t D_+^{2\beta} u(x, t) = \lambda^2 \frac{\partial^2}{\partial x^2} u(x, t), \quad \lambda > 0, \quad x \geq 0, \quad -\infty < t < \infty, \quad 0 < 2\beta < 1, \quad (3)$$

$$u(0, t) = A e^{i\omega t}, \quad \omega \in \mathbb{R}^+,$$

где оператор ${}_t D_+^{2\beta}$ представляет собой дробную производную Римана — Лиувилля (2), когда нижний предел интеграла равен $-\infty$.

В работе [8] впервые определялся порядок α дифференцирования по переменной t (экспонента Хёрста). Эта задача позже рассматривалась в [10], где в одномерном случае была доказана единственность. Большое количество типов обратных задач приведено в работе [11], в которых определяются: начальное распределение $u(x, 0)$ по данным $u(x, T)$, заданным в некоторый момент времени T ; граничные условия $u(0, t) = f(t)$ по зашумленным данным, измеряемым в некоторой промежуточной точке L : $h(t) = u(L, t)$. В [11] рассматривается обратная задача Штурма — Лиувилля для задач с операторами дробного дифференцирования по пространственной переменной. В [12] рассмотрена обратная задача восстановления порядка дифференцирования α и коэффициента диффузии $p(x)$ уравнения

$${}_t D_*^\alpha u(x, t) = \frac{\partial}{\partial x} \left(p(x) \frac{\partial u}{\partial x}(x, t) \right), \quad 0 < x < l, \quad 0 < t < T,$$

$$u(x, t) = \delta(x),$$

$$\frac{\partial u}{\partial x}(0, t) = \frac{\partial u}{\partial x}(l, t), \quad 0 < t < T,$$

с использованием данных на границе $u(0, t)$, $0 < t \leq T$. В [12] рассмотрена другая постановка обратной задачи — восстановление неизвестной функции на некоторой границе: $\frac{\partial u}{\partial \nu} = f(u)$. Используя свойства фундаментального решения, авторы получают f в виде решения нелинейного интегрального уравнения

Вольтерра второго рода со слабо сингулярным ядром. В [13] рассматривается обратная задача по определению неизвестных параметров α и β системы

$$\begin{aligned} {}_t\mathcal{D}_*^\alpha u(x, t) &= \Delta^{\beta/2} u(x, t), \quad -1 < x < 1, \quad 0 < t < T, \\ u(-1, t) &= u(1, t) = 0, \quad 0 < t < T, \\ u(x, 0) &= f(x), \quad -1 < x < 1, \end{aligned} \quad (4)$$

где f — некоторая заданная функция по данным на оси $x = 0$: $u(0, t) = g(t)$, $0 < t < T$.

В работе исследуется обратная задача восстановления параметра α (во вторую очередь — постоянного коэффициента диффузии λ) на основе значений наблюдаемой функции в некоторой точке x_0 . Данную обратную задачу можно рассматривать как промежуточную между задачами (3) и (4). Выбор исходных данных для обратной задачи физически естественен: исследователь наблюдает показания датчика, расположенного в некоторой точке пространства (в работе [13] $x_0 = 0$). В качестве метода решения нами был выбран метод искусственных нейронных сетей. Этот подход успешно применялся в работах [14–16] для решения классических обратных задач.

ОБРАТНАЯ ЗАДАЧА ДЛЯ УАД. Сначала сформулируем прямую задачу. Рассмотрим область $\Omega = \{(x, t) : 0 \leq x \leq 1, t \geq 0\}$. В данной области рассмотрим краевую задачу для одномерного уравнения диффузии дробного порядка по времени:

$$\begin{aligned} {}_t\mathcal{D}_*^\alpha u &= \lambda^2 \frac{\partial^2}{\partial x^2} u, \quad 0 < \alpha \leq 1, \quad 0 < \lambda \leq 1, \\ u(x, 0) &= u_0(x), \quad 0 \leq x \leq 1, \\ u(0, t) &= u(1, t) = 0, \quad t > 0. \end{aligned} \quad (5)$$

Здесь $u = u(x, t)$, $|u(x, t)| < M$ для некоторой константы M ; $u_0 \in C([0, 1])$; ${}_t\mathcal{D}_*^\alpha$ — оператор дробного дифференцирования Капуто (1) порядка α .

Если прямая задача состоит в нахождении решения уравнения (5) при заданных параметрах, то обратная задача состоит в определении параметров системы при наличии некоторых знаний о свойствах решения.

Чтобы точно сформулировать обратную задачу, выберем некоторую точку $x_0 \in (0, 1)$. Ограничим время наблюдения данных о концентрации вещества значением $0 \leq t \leq 1$. Выберем N — число измерений данных о концентрации вещества. Измерим данные о концентрации вещества $u_i = u(x_0, t_i)$ в моменты времени $t_i = i/N$, $i = 0, 1, \dots, N$. Известно, что функция $u(x, t)$ удовлетворяет задаче (5) с некоторыми параметрами α и λ . Нашей целью является определение неизвестных параметров α и/или λ по заданным значениям u_i . Более точно рассматриваемые обратные задачи для УАД описаны в табл. 1.

Т а б л и ц а 1

Обратные задачи аномальной диффузии

	Входные данные обратной задачи	Восстанавливаемые данные
Обратная задача 1	$x_0, u_i, i = 0, 1, \dots, N$	α, λ
Обратная задача 2	$x_0, u_i, i = 0, 1, \dots, N$	α
Обратная задача 3	$x_0, \lambda, u_i, i = 0, 1, \dots, N$	α

Заметим, что в обратной задаче 2 параметр λ не задается и его определение не требуется.

Список обратных задач может быть расширен за счет отказа от использования данных о координате точки, в которой производится измерение (см. табл. 2). Физически это означает, что мы не можем достоверно сказать, в какой точке пространства мы ведем наблюдение, не можем определить расстояние от точки измерения до границы области.

Т а б л и ц а 2

Расширенные постановки обратных задач аномальной диффузии

	Входные данные обратной задачи	Восстанавливаемые данные
Обратная задача 4	$u_i, i = 0, 1, \dots, N$	α, λ
Обратная задача 5	$u_i, i = 0, 1, \dots, N$	α
Обратная задача 6	$\lambda, u_i, i = 0, 1, \dots, N$	α

3. Модель искусственных нейронных сетей. На практике архитектура нейронной сети выбирается, как правило, исходя из конкретной задачи. В работе рассматривается нейронная сеть типа многослойный персептрон.

ОПРЕДЕЛЕНИЕ 3. Многослойным персептроном (см. рис. 1) называется нейронная сеть, в которой входной сигнал распространяется в прямом направлении — от слоя к слою. В общем случае многослойный персептрон состоит из множества входных нейронов, образующих входной слой; одного или нескольких скрытых слоев; одного слоя выходных нейронов.




Рис. 1. Многослойный персептрон

Многослойный персептрон представляет собой обучаемую нейронную сеть. Обучение нейронной сети состоит в предъявлении примеров, состоящих из наборов входных данных, совместно с соответствующим результатом наблюдения. С математической точки зрения обучение представляет собой процедуру настройки свободных параметров нейронной сети, направленную на минимизацию расхождения фактических вычисленных выходных сигналов сети с требуемыми результатами обучающих примеров.

Итерация обучения нейронной сети состоит в корректировке свободных параметров (весов w_i , функции состояния $s(x)$, функции активации $f(s)$ нейрона или графа сети) так, чтобы нейронная сеть решала поставленную задачу минимизации ошибки.

На практике для обучения персептронных нейронных сетей часто применяется алгоритм обратного распространения ошибки, для которого доказана сходимость [17]. При обучении ошибка распространяется обратно по сети, корректируя веса нейронов, предотвращающая повторное возникновение данной ошибки.

Для k -го нейрона коррекция весов w_{kj} выглядит следующим образом [15]: $\Delta w_{kj} = \eta \delta_k y_j$, где δ_k — локальный градиент; y_j — входной сигнал нейрона k ; η — обучающий коэффициент, регулирующий степень изменения весов.

4. Решение обратной задачи методом искусственных нейронных сетей. Как отмечалось выше, в работе в качестве модели нейронной сети был

выбран многослойный персептрон с несколькими входами и одним (соответствующим восстанавливаемому параметру α) или двумя (соответствующими восстанавливаемым параметрам α и λ) выходами.

Сформированы шесть типов нейронных сетей с разными входными и выходными параметрами (см. табл. 3), отличающимися друг от друга количеством нейронов на разных слоях (см. табл. 4).

Т а б л и ц а 3

Типы нейронных сетей

Тип нейронной сети	Входные параметры	Выходные параметры
Нейронная сеть 1	$(x_0, u_0, u_1, \dots, u_N)$	α, λ
Нейронная сеть 2	$(x_0, u_0, u_1, \dots, u_N)$	α
Нейронная сеть 3	$(x_0, \lambda, u_0, u_1, \dots, u_N)$	α
Нейронная сеть 4	$(u_0, u_1, \dots, u_N)$	α, λ
Нейронная сеть 5	$(u_0, u_1, \dots, u_N)$	α
Нейронная сеть 6	$(\lambda, u_0, u_1, \dots, u_N)$	α

Здесь x_0 — «координата наблюдения» функции концентрации, удовлетворяющей задаче (5) со значениями α, λ и $u_0(x)$, $u_i = u(x_0, t_i)$, $t_i = i/N$.

Т а б л и ц а 4

Количество нейронов на слоях нейронных сетей

Тип нейронной сети	Слой 1	Слой 2	Слой 3
Нейронная сеть 1	$N + 2$	$N/2$	$N/4$
Нейронная сеть 2	$N + 2$	$N/2$	$N/4$
Нейронная сеть 3	$N + 3$	$N/2$	$N/4$
Нейронная сеть 4	$N + 1$	$N/2$	$N/4$
Нейронная сеть 5	$N + 1$	$N/2$	$N/4$
Нейронная сеть 6	$N + 2$	$N/2$	$N/4$

Типы нейронных сетей охватывают нейронные сети, восстанавливающие одновременно пару (α, λ) , только параметр α , а также нейронные сети, в которых x_0 и λ являются входными параметрами. Каждая из рассматриваемых нейронных сетей состоит из трех слоев.

В качестве функции состояния нейрона была выбрана взвешенная сумма: $s(x) = \sum_{i=1}^n x_i w_i$. Нелинейной функцией активации выбрана сигмоида $f(s) = s/(c + |s|)$ (см. рис. 2).

Параметр c выбирается одинаковым для каждого нейрона заданного слоя, на разных слоях значения параметра c могут различаться. Во всех рассмотренных случаях параметр сигмoиды c полагался равным 0,1.

С физической точки зрения количество измерений N связано с разрешающей способностью приборов, измеряющих концентрацию вещества в заданной точке. Для простоты будем считать, что $N = 10 \cdot 2^k$, $k \in \mathbb{N}$, каждый раз увеличивая вдвое точность прибора. Очевидным образом число измерений не может быть очень большим (в работе [15] $N = 15$), хотя его увеличение, как будет показано ниже, повышает точность решения обратной задачи.

В качестве базовых типов нейронных сетей выбирались нейронные сети с числом входов, соответствующих количеству измерений $N = 20$ и $N = 40$




Рис. 2. График сигмоиды для различных значений параметра c

(случай $N = 10$ дает достаточно большую ошибку, поэтому будет пропущен, а конфигурация с $N = 80$ накладывает определенные ограничения на измерительные приборы, требуется большая разрешающая способность).

5. Построение точных решений для обучения нейронной сети.

Обучение нейронной сети требует наличия некоторого количества обучающих примеров. Построим обучающее множество, используя точные аналитические решения прямой задачи (5). Альтернативой точным аналитическим решениям могут быть численные решения прямой задачи, но применение их для обучения нецелесообразно. Приближенное численное решение содержит в себе некоторую ошибку вычислений, и эта ошибка может сказываться на качестве обучения нейронной сети. Опишем алгоритм получения точных решений.

Представив функцию $u(x, t)$ в виде произведения $u(x, t) = X(x)T(t)$, получим, что функции $u_n(x, t) = X_n(x)T_n(t) = C_n E_\alpha(-\pi^2 n^2 \lambda^2 t^\alpha) \sin(\pi n x)$ являются частными решениями задачи (5). Здесь $E_\alpha(z)$ — функция Миттаг — Леффлера:

$$E_\alpha(z) = \sum_{k=0}^{\infty} \frac{z^k}{\Gamma(\alpha k + 1)}, \quad \alpha > 0.$$

Следуя работам [18, 19], представим решение задачи (5) в виде ряда:

$$u(x, t) = \sum_{n=0}^{\infty} C_n E_\alpha(-\pi^2 n^2 \lambda^2 t^\alpha) \sin(\pi n x). \quad (6)$$

Функция $u(x, t)$, задаваемая равенством (6), очевидным образом удовлетворяет дифференциальному уравнению и граничным условиям задачи (5), так как им удовлетворяют все члены ряда. Заметим, что коэффициенты C_n являются коэффициентами Фурье функции $u_0(x)$ при разложении ее в ряд по синусам на интервале $(0, 1)$: $C_n = 2 \int_0^1 u_0(y) \sin(\pi n y) dy$. Данное соотношение следует из

начального условия задачи (5): $u_0(x) = u(x, 0) = \sum_{n=0}^{\infty} C_n \sin(\pi n x)$.

6. Обучение нейронных сетей. Обучение нейронных сетей производилось алгоритмом обратного распространения ошибки.

Будем считать, что нейронная сеть правильно распознает входной пример, если абсолютное значение отклонения прогноза от истинного значения составляет не более 0,1 (т. е. 10 % от максимального значения параметров α и λ). Здесь и далее под ошибкой E понимается абсолютное значение величины расхождения истинного значения восстанавливаемого параметра и прогнозного.

В качестве множества для обучения нейронной сети на основе точных решений было сформировано 1000 примеров (данное множество будем именовать обучающим). Для тестирования было сформировано отдельное множество из 500 примеров, не имеющее пересечений с обучающим (далее тестовым). Для исследования влияния шума на результат прогноза в указанные множества искусственно был привнесен шум в размере не более 5 % (далее обучающее + 5 % шум, тестовое + 5 % шум). Для нейронных сетей, соответствующих $N = 40$, обучающее множество состояло из 3000 примеров, тестовое — из 1000.

Поясним подробнее, как формировались примеры для обучения и тестирования. Для построения точных решений прямой задачи (5) воспользуемся формулой (6). Эти точные решения, соответствующие заданным значениям α и λ , будут использоваться при обучении.

Алгоритм построения примеров для обучения нейронной сети (для заданного значения N) состоит из следующих шагов.

ШАГ 1. Выберем случайным образом с равномерным распределением в интервале $(0, 1)$ параметры α и λ .

ШАГ 2. Аналогичным образом выберем некоторое количество коэффициентов C_n из интервала $(-10, 10)$ (значения нижнего индекса n не обязательно выбирать последовательными).

ШАГ 3. Подставив выбранные значения в (6), получим функцию $u(x, t)$, состоящую из конечного числа слагаемых и удовлетворяющую системе (5).

ШАГ 4. Для получения входных данных для обратной задачи достаточно выбрать координату точки измерения $x_0 \in (0, 1)$ и вычислить значения $u_i = u(x_0, t_i) = u(x_0, i/N)$.

Выполнив последовательно шаги 1–4, получим пример для обучения или тестирования нейронной сети, основанный на точном решении дифференциальной задачи.

Для формирования зашумленных данных $\tilde{u}_i$ во входные данные для нейронной сети на шаге 4 вносился аддитивный шум: к точному решению u_i добавлялась некоторая случайная ошибка ξ_i ($\tilde{u}_i = u_i + \xi_i$), равномерно распределенная на симметричном относительно нуля интервале $[-E_{\max} u_i, E_{\max} u_i]$. Значение определяет максимальный уровень вносимой ошибки. Эти данные необходимы для понимания того, насколько нейронная сеть восприимчива к шуму во входных данных. Физически он соответствует ошибке измерения функции концентрации вещества в заданной точке наблюдения.

7. Результат обучения нейронных сетей. Результат обучения нейронных сетей вида 1–6 (для $N = 20$) представлен в табл. 5, 6 и на рис. 3. Табл. 5, 6 содержат данные о доле правильно восстановленных значений параметров α и λ (считаем, что параметр был восстановлен нейронной сетью правильно, если ошибка восстановления составила не более 0,1), о средней $\bar{E}$ и максимальной $E_{\max}$ ошибках восстановления параметров, а также о дисперсии D ошибки для обучающего или тестового множества из K элементов:

$$\bar{E} = \frac{1}{K} \sum E_i, \quad D = \frac{1}{K} \sum (E_i - \bar{E})^2.$$

Нас интересует абсолютное значение ошибки, поэтому здесь и далее будем считать что ошибка принимает неотрицательное значение.

Средняя ошибка восстановления параметра α попадает в интервал $[0, 05; 0, 08]$. Это означает, что выбранный нами тип нейронных сетей достаточно хорошо позволяет восстановить параметр α задачи (5). В то же самое время средняя ошибка восстановления параметра λ достаточно высока (больше заданного нами порога 0,1 достаточности восстановления), поэтому использование нейронных сетей с рассматриваемыми выходными данными и рассматриваемой структурой вряд ли целесообразно.

Т а б л и ц а 5

Результат обучения нейронной сети
и тестирование на зашумленном обучающем множестве

Сеть		Обучающее		Обучающее + 5 % шум	
		α	λ	α	λ
1	Правильно	68,20 %	35,60 %	67,60 %	36,20 %
	Средняя ошибка	0,0787	0,1430	0,0827	0,1441
	Макс. ошибка	0,3728	0,5027	0,9759	0,5047
	Дисперсия ошибки	0,0030	0,0088	0,0046	0,0089
2	Правильно	86,00 %		82,40 %	
	Средняя ошибка	0,0604		0,0641	
	Макс. ошибка	0,3622		0,4495	
	Дисперсия ошибки	0,0020		0,0028	
3	Правильно	88,70 %		82,40 %	
	Средняя ошибка	0,0583		0,0634	
	Макс. ошибка	0,2045		0,8540	
	Дисперсия ошибки	0,0013		0,0029	
4	Правильно	77,10 %	39,50 %	75,80 %	38,60 %
	Средняя ошибка	0,0671	0,1449	0,0712	0,1466
	Макс. ошибка	0,3594	0,5603	0,7292	0,5605
	Дисперсия ошибки	0,0025	0,0103	0,0036	0,0104
5	Правильно	88,50 %		84,20 %	
	Средняя ошибка	0,0574		0,0651	
	Макс. ошибка	0,3233		1,4295	
	Дисперсия ошибки	0,016		0,0057	
6	Правильно	80,60 %		79,00 %	
	Средняя ошибка	0,0631		0,0683	
	Макс. ошибка	0,2647		0,8166	
	Дисперсия ошибки	0,0018		0,0037	

Стоит отметить, что наблюдаемое в табл. 5 совпадение количества правильно и неправильно распознанных образов нейронной сетью 1 является случайностью: при добавлении шума к обучающим данным общее число правильно распознанных образов не менялось, а средняя ошибка несколько увеличилась.

Представленные численные эксперименты позволяют сформулировать следующие выводы.

1. Модель искусственных нейронных сетей (многослойный персептрон) показала себя достаточно эффективной для численного решения обратных задач аномальной диффузии по определению показателя дробного дифференцирования α . Средняя ошибка восстановления попадает в интервал $[0, 05; 0, 08]$.

2. Коэффициент диффузии предложенным методом на основе рассматриваемых входных данных задачи восстанавливается существенно хуже. По всей видимости, для улучшения точности определения коэффициента λ требуются дополнительные данные.

Т а б л и ц а 6

Тестирование нейронной сети
на тестовом и зашумленном тестовом множестве

Сеть		Тестовое		Тестовое + 5% шум	
		α	λ	α	λ
1	Правильно	65,20 %	34,80 %	63,60 %	33,00 %
	Средняя ошибка	0,0997	0,1682	0,1032	0,1687
	Макс. ошибка	0,7490	0,6681	0,7668	0,6675
	Дисперсия ошибки	0,0097	0,0145	0,0112	0,0143
2	Правильно	77,60 %		76,20 %	
	Средняя ошибка	0,0789		0,0843	
	Макс. ошибка	0,8874		0,7064	
	Дисперсия ошибки	0,0068		0,0092	
3	Правильно	73,80 %		71,00 %	
	Средняя ошибка	0,0895		0,0939	
	Макс. ошибка	0,9298		0,9716	
	Дисперсия ошибки	0,0102		0,0118	
4	Правильно	75,00 %	38,40 %	75,00 %	39,20 %
	Средняя ошибка	0,0756	0,1626	0,0782	0,1625
	Макс. ошибка	0,6543	0,8854	0,8313	0,8898
	Дисперсия ошибки	0,0062	0,0170	0,0075	0,0165
5	Правильно	82,80 %		80,60 %	
	Средняя ошибка	0,0688		0,0780	
	Макс. ошибка	0,9258		0,9773	
	Дисперсия ошибки	0,0066		0,0111	
6	Правильно	74,80 %		73,40 %	
	Средняя ошибка	0,0838		0,0837	
	Макс. ошибка	0,7624		0,7641	
	Дисперсия ошибки	0,0080		0,0079	

3. Метод показал себя устойчивым к шуму в начальных данных: в большинстве рассматриваемых моделей внесение шума в исходные данные обратной задачи в размере не более 5 % дает 5–7 % снижения точности распознавания и весьма незначительное увеличение средней ошибки (порядка 0,02–0,03).

Но наиболее неожиданным, на наш взгляд, результатом является то, что дополнительное знание о расположении измерительного прибора (координата x_0) не дает существенного повышения точности определения параметра дробного дифференцирования α . Этот факт позволяет выдвинуть гипотезу о том, что предложенный метод может быть успешно применен для решения обратной задачи в области $\Omega' = \{(x, t) : -\infty < x < \infty, t \geq 0\}$.

Данные в табл. 5, 6 дают представление о максимальной ошибке восстановления параметров задачи (5), но не говорят о том, как часто возникает ошибка, большая допустимой.

Разобьем отрезок $[0, 2]$ на 11 интервалов $[0, 00; 0, 02)$, $[0, 02; 0, 04)$, $[0, 04; 0, 06)$, $[0, 06; 0, 08)$, $[0, 08; 0, 10)$, $[0, 10; 0, 12)$, $[0, 12; 0, 14)$, $[0, 14; 0, 16)$, $[0, 16; 0, 18)$,




Рис. 3. Распределение ошибки восстановления параметра α нейронной сети на обучающем и зашумленном множествах

$[0, 18; 0, 20)$, $[0, 20; 2, 00)$ (число 2 ограничивает сверху максимальную ошибку восстановления). Последний интервал соответствует недопустимой ошибке восстановления. Вычислим доли ошибок, попадающих в эти интервалы.

На рис. 3 представлены доли ошибок, попадающих в соответствующие интервалы, для множеств «обучающее» (темно-серые столбцы) и «обучающее + 5 % шум» (светло-серые столбцы) для каждого типа нейронных сетей (левые гистограммы соответствуют нейронным сетям вида 1–3, правые — нейронным сетям вида 4–6).

Данные гистограммы позволяют сделать вывод об устойчивости нейронных сетей к шуму во входных данных. Шум в размере 5 % почти всегда дает такую же ошибку в количестве правильно распознанных примеров: ошибка сохраняет свойство локальности.

Численный эксперимент демонстрирует, что для рассматриваемых нейронных сетей доля ошибок, больших 0,1, резко уменьшается. Это говорит о том, что рассмотренные нейронные сети улавливают внутренние закономерности данных и достаточно хорошо позволяют восстановить параметры рассматриваемой обратной задачи аномальной диффузии.

Чтобы показать, как изменяется точность восстановления параметров α и λ с увеличением частоты измерения концентрации вещества, приведем результаты обучения нейронных сетей с количеством измерений $N = 40$ в табл. 7.

Т а б л и ц а 7

Точность решения обратной задачи
при увеличении дискретности измерений N

Сеть	$N = 20$		$N = 40$	
	α , %	λ , %	α , %	λ , %
1	68,20	35,60	75,67	44,20
2	86,00		86,07	
3	88,70		89,73	
4	77,10	39,50	81,03	36,47
5	88,50		89,40	
6	80,60		87,47	

Таким образом, увеличение числа измерений концентрации вещества с $N = 20$ до $N = 40$ по всем видам нейронных сетей дало увеличение точности распознавания показателя дробного дифференцирования α .

Представлены результаты численного решения обратных задач для уравнения аномальной диффузии по восстановлению параметров дробного дифференцирования и характеристики среды методами искусственных нейронных сетей. В качестве входных данных для обратных задач выбирались измерения значения функции концентрации вещества в фиксированной точке x_0 в различные моменты времени. Численные эксперименты показали хорошее качество восстановления показателя дробного дифференцирования α (как на точных, так и на зашумленных данных), в то время как характеристика среды λ восстанавливается по используемым данным предложенным методом значительно хуже. По всей видимости, для его восстановления необходимо выбирать другие исходные данные обратной задачи, существенно зависящие не только от времени, но и от координаты.

ЛИТЕРАТУРА

1. Нигматуллин Р. Р. Дробный интеграл и его физическая интерпретация // Теор. и мат. физика. 1992. V. 90, № 3. С. 354–368.
2. Mainardi F. The fundamental solutions for the fractional diffusion-wave equation // Appl. Math. Lett. 1996. V. 9, N 6. P. 23–28.
3. Metzler R., Klafter J. The random walk's guide to anomalous diffusion: a fractional dynamics approach // Phys. Rep. 2000. V. 339. P. 1–77.
4. Montroll E. W., Weiss G. H. Random walks on lattices. II // J. Math. Phys. 1965. V. 6. P. 167–178.
5. Barkai E., Metzler R., Klafter M. From continuous time random walks to the fractional Fokker–Plank equation // Phys. Rev. E. 2000. V. 61. P. 132–138.
6. Gorenflo R., Mainardi F., Moretti D., Pagnini G., Paradisi P. Discrete random walk models for space-time fractional diffusion // Chem. Phys. 2002. V. 284. P. 521–541.
7. Gorenflo R., Vivoli A., Mainardi F. Discrete and continuous random walk models for space-time fractional diffusion // Nonlinear Dynamics. 2004. V. 38. P. 101–116.
8. Bondarenko A. N., Ivaschenko D. S. Generalized Sommerfeld problem for time fractional diffusion equation: analytical and numerical approach // J. Inverse Ill-Posed Probl. 2009. V. 17, N 4. P. 319–333.
9. Bondarenko A. N., Ivaschenko D. S. Numerical methods for solving inverse problems for time fractional diffusion equation with variable coefficient // J. Inverse Ill-Posed Probl. 2009. V. 17, N 5. P. 419–440.
10. Cheng J., Nakagawa J., Yamamoto M., Yamazaki T. Uniqueness in an inverse problem for a one-dimensional fractional diffusion equation // Inverse Probl. 2009. V. 25, N 11. 115002; doi:10.1088/026605611/25/11/115002.

11. Jin B., Rundell W. A tutorial on inverse problems for anomalous diffusion processes // Inverse Probl. 2015. V. 31, N 3. 035003; doi:10.1088/0266-5611/31/3/035003.
12. Rundell W., Xu X., Zuo L. The determination of an unknown boundary condition in a fractional diffusion equation // Appl. Anal. 2013. V. 92, N 7. P. 1511–1526.
13. Tatar S., Ulusoy S. A uniqueness result for an inverse problem in a space-time fractional diffusion equation // Electron. J. Differential Equations. 2013. V. 2013, N 258. P. 1–9.
14. Mahmoud M. A., Abu Kiefa M. A. Neural network solution of the inverse vibration problem // NDT and E Internat. 1999. V. 32, N 2. P. 91–99; doi:10.1016/S0963-8695(98)00026-7.
15. Shiguemori E. H., Chiwiacowsky L. D., De Campos Velho H. F., Da Silva J. D. S. An inverse vibration problem solved by an artificial neural network // TEMA Tend. Mat. Appl. Comput. 2005. V. 6, N 1. P. 163–175; doi: 10.5540/tema.2005.06.01.0163.
16. Barai S. V., Pandey P. C. Time-delay neural networks in damage detection of railway bridges // Adv. Engrg. Software. 1997. V. 28. P. 1–10.
17. Уоссермен Ф. Нейрокомпьютерная техника. М.: Мир, 1992.
18. Тихонов А. Н., Самарский А. А. Уравнения математической физики. М.: Наука, 1977.
19. Yuste S. B., Acedo L. An explicit finite difference method and a new von Neumann-type stability analysis for fractional diffusion equations // SIAM J. Numer. Anal. 2005. V. 42. P. 1862–1874.

Статья поступила 2 сентября 2015 г.

Бондаренко Анатолий Николаевич

Институт математики им. С. Л. Соболева СО РАН

просп. Акад. Коптюга, 4

Бугуева Татьяна Владимировна

Институт математики им. С. Л. Соболева СО РАН

Новосибирский государственный университет

ул. Пирогова, 2

Дедок Василий Александрович

Институт математики им. С. Л. Соболева СО РАН

630090 г. Новосибирск

E-mail: bondarenkoan1953@mail.ru; bugueva@math.nsc.ru; dedok@math.nsc.ru